

§ 7.3 平衡二叉搜索树

7.3.1 树高与性能

根据7.2节对二叉搜索树的实现与分析，`search()`、`insert()`和`remove()`等主要接口的运行时间，均线性正比于二叉搜索树的高度。而在最坏情况下，二叉搜索树可能彻底地退化为列表，此时的查找效率甚至会降至 $O(n)$ ，线性正比于数据集的规模。因此，若不能有效地控制树高，则就实际的性能而言，较之此前的向量和列表，二叉搜索树将无法体现出明显优势。

那么，出现上述最坏（或较坏）情况的概率有多大？或者，至少从平均复杂度的角度来看，二叉搜索树的性能是否还算令人满意？

以下，将按照两种常用的随机统计口径，就二叉搜索树的平均性能做一比较。

■ 随机生成

不妨设各节点对应于 n 个互异关键码 $\{e_1, e_2, \dots, e_n\}$ 。于是按照每一排列：

$$\sigma = (e_{i_1}, e_{i_2}, \dots, e_{i_n})$$

只要从空树开始，通过依次执行`insert( $e_{i_k}$ )`，即可得到这 n 个关键码的一棵二叉搜索树 $T(\sigma)$ 。与随机排列 σ 如此相对应的二叉搜索树 $T(\sigma)$ ，称作由 σ “随机生成”（randomly generated）。

图7.9以三个关键码 $\{1, 2, 3\}$ 为例，列出了由其所有排列所生成的二叉搜索树。




图7.9 由三个关键码 $\{1, 2, 3\}$ 的6种全排列生成的二叉搜索树

显然，任意的 n 个互异关键码，都可以构成 $n!$ 种全排列。若各排列作为输入序列的概率均等，则只要将它们各自所生成二叉搜索树的平均查找长度进行平均，即可在一定程度上反映二叉搜索树的平均查找性能。可以证明^{[29][30]}，在这一随机意义下，二叉搜索树的平均高度为 $\Theta(\log n)$ 。

■ 随机组成

另一随机策略是，假定 n 个互异节点同时给定，然后在遵守顺序性的前提下，随机确定它们之间的拓扑联接。如此，称二叉搜索树由这组节点“随机组成”（randomly composed）。

实际上，由 n 个互异节点组成的二叉搜索树，总共可能有 $(2n)!/n!/(n+1)!$ 棵（习题[7-2]）。若这些树出现的概率均等，则通过对其高度做平均可知^[30]，平均查找长度为 $\Theta(\sqrt{n})$ 。

■ 比较

前一口径的 $\Theta(\log n)$ 与后一口径的 $\Theta(\sqrt{n})$ 之间，就渐进意义而言有实质的差别。原因何在？

读者也许已经发现，同一组关键码的不同排列所生成的二叉搜索树，未必不同。仍以图7.9为例，排列 $(2, 1, 3)$ 与 $(2, 3, 1)$ 生成的，实际上就是同一棵二叉搜索树。而在按照前一口径估计平均树高时，这棵树被统计了两次。实际上一一般而言，越是平衡的树，被统计的次数亦越多。从这个角度讲，前一种平均的方式，在无形中高估了二叉搜索树的平均性能。因此相对而言，按照后一口径所得的估计值更加可信。

■ 树高与平均树高

实际上，即便按照以上口径统计出平均树高，仍不足以反映树高的随机分布情况。实际上，树高较大情况的概率依然可能很大。另外，理想的随机并不常见，实际应用中的情况恰恰相反，一组关键码往往会按照（接近）单调次序出现，因此频繁出现极高的搜索树也不足为怪。

另外，若`removeAt()`操作的确如代码7.7所示，总是固定地将待删除的二度节点与其直接后继交换，则随着操作次数的增加，二叉搜索树向左侧倾斜的趋势将愈发明显（习题[7-9]）。

7.3.2 理想平衡与适度平衡

■ 理想平衡

既然二叉搜索树的性能主要取决于高度，故在节点数目固定的前提下，应尽可能地降低高度。相应地，应尽可能地使兄弟子树的高度彼此接近，即全树尽可能地平衡。当然，包含 n 个节点的二叉树，高度不可能小于 $\lfloor \log_2 n \rfloor$ （习题[7-3]）。若树高恰好为 $\lfloor \log_2 n \rfloor$ ，则称作理想平衡树。例如，如图5.26所示的完全二叉树，甚至如图5.27所示的满二叉树，均属此列。

遗憾的是，完全二叉树“叶节点只能出现于最底部两层”的限制过于苛刻。略做简单的组合统计不难发现，相对于二叉树所有可能的形态，此类二叉树所占比例极低；而随着二叉树规模的增大，这一比例还将继续锐减（习题[7-2]）。由此可见，从算法可行性的角度来看，有必要依照某种相对宽松的标准，重新定义二叉搜索树的平衡性。

■ 适度平衡

在渐进意义下适当放松标准之后的平衡性，称作适度平衡。

幸运的是，适度平衡的标准的确存在。比如，若将树高限制为“渐进地不超过 $O(\log n)$ ”，则下节将要介绍的AVL树，以及下一章将要介绍的伸展树、红黑树、kd-树等，都属于适度平衡。这些变种，因此也都可归入平衡二叉搜索树（balanced binary search tree, BBST）之列。

7.3.3 等价变换

■ 等价二叉搜索树

如图7.10所示，若两棵二叉搜索树的中序遍历序列相同，则称它们彼此等价；反之亦然。




图7.10 由同一组共11个节点组成，相互等价的两棵二叉搜索树（二者在拓扑上的差异，以阴影圈出）

由该图也不难看出，虽然等价二叉搜索树中各节点的垂直高度可能有所不同，但水平次序完全一致。这一特点可概括为“上下可变，左右不乱”，它也是以下等价变换的基本特性。